Wie sicher sind die KI-Modelle der Universität Bielefeld?

Ein Test von vier Sprachmodellen auf BiKi

20.07.2026
Unsicherheit in Sprachmodellen: Messen, Handhaben, Kommunizieren, Reduzieren (S) (SoSe 2026)

BIKI – Bielefelder KI Portal

Eine Anwendung für Chats mit großen Sprachmodellen

Das KI-Portal "BIKI" wurde entwickelt, um den Nutzer*innen der Universität Bielefeld eine anbieterunabhängige Lösung zur Nutzung von Künstlicher Intelligenz basierend auf einem Large Language Model zu schaffen.

Ein Large Language Model (LLM) ist ein KI-Modell, das auf großen Textdatensätzen trainiert wird, um menschenähnliche Sprache



© Universität Bielefeld

Getestete KI-Modelle

ChatGPT 5.4

ChatGPT 5.4 mini

DeepSeek V4 Flash

Qwen 3.6 35 B

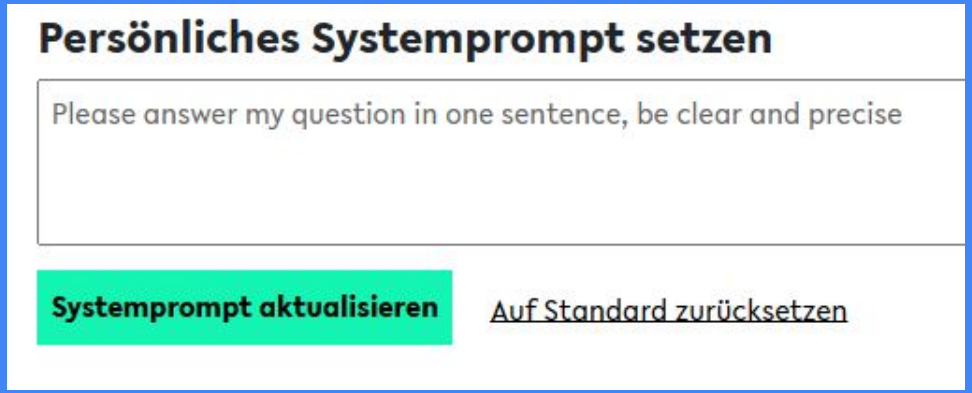
Testbedingungen

50 Fragen pro Modell

Alle Modelle bekamen dieselben Fragen.

Jede Frage wurde in einem neuen Chat gestellt.

Die Modelle hatten keinen Zugang zum Internet. Deshalb konnten sie keine Informationen im Internet nachschauen.



Fragen aus verschiedenen Bereichen

Geschichte

Technik

Literatur

Musik, Serien und Computerspiele

Wissenschaft

Allgemeinwissen

Sehr spezielle Fakten

Beispiele:

How much VRAM does the most budget-friendly graphics card in NVIDIA's 1000 series have?

How many elements in the periodic table are named after countries?

What was Margaret Thatcher's original profession before entering politics?

Who designed the logo of Bielefeld University?

Bewertung

War die Antwort richtig?
1 = richtig
0 = falsch

Wie sicher klang die Antwort?

HI = sehr sicher
LO = vorsichtig oder unsicher
DK = „weiß ich nicht“ / keine sichere Antwort möglich

Model answer	Correct (0/1)	Confidence (HI/LO/DK)
Elon Musk's first car was a 1985 Ford Mustang GT.	0	HI
Judith Butler's doctoral dissertation was supervised by the philosopher Stanley Cavell.	0	HI
Margaret Thatcher originally worked as a research chemist before qualifying and practicing as a barrister specializing in	1	HI
Angela Merkel learned to play the piano and the violin as a child.	1	HI
Freddie Mercury's birth name was Farrokh Bulsara.	1	HI
Built-in computer games were first introduced in Windows 2.0, which originally featured Solitaire to demonstrate mouse	0	HI
The default wallpaper in Windows XP was called "Bliss."	1	HI

Ich war bei der Bewertung relativ kulant und habe eine Antwort auch dann als richtig gewertet, wenn einzelne Teile möglicherweise Fehler enthielten.

How much VRAM does the most budget-friendly graphics card in NVIDIA's 1000 series have?

Qwen: The most budget-friendly NVIDIA GeForce GTX 1000 series graphics card is the GTX 1050, which features 2 GB of GDDR5 VRAM.

GPT-5.4: The most budget-friendly NVIDIA 1000-series card, the GeForce GT 1030, has 2 GB of VRAM.

GPT-5.4 mini: The most budget-friendly NVIDIA GeForce GTX 1050 in the 1000 series typically has 2 GB of VRAM.

DeepSeek: The most budget-friendly graphics card in NVIDIA's 1000 series is the GTX 1050, which has 2GB of VRAM.

Qwen: viele sichere, aber falsche Antworten

Richtige Antworten: 25 von 50
Falsche Antworten: 25 von 50
Genauigkeit: 50%

Sicherheit der Antworten:

HI: 49 Antworten
LO: 0 Antworten
DK: 1 Antwort

Verbindung von Sicherheit und Richtigkeit:

Richtig + HI: 24
Falsch + HI: 25
Richtig + DK: 1



Qwen antwortete fast immer sehr sicher.

Es gab keine vorsichtigen Antworten mit LO.

Fast jede zweite Antwort war falsch.

Viele falsche Antworten klangen trotzdem eindeutig und überzeugend.

DeepSeek: etwas besser, aber oft zu sicher

Richtige Antworten: 27 von 50
Falsche Antworten: 23 von 50
Genauigkeit: 54%

Sicherheit der Antworten:

HI: 45 Antworten
LO: 2 Antworten
DK: 3 Antworten

Verbindung von Sicherheit und Richtigkeit:

Richtig + HI: 25
Falsch + HI: 20
Richtig + LO: 1
Falsch + LO: 1
Richtig + DK: 1
Falsch + DK: 2



Deepseek war nur wenig besser als Qwen.

Die meisten Antworten waren HI.

20 falsche Antworten klangen trotzdem sehr sicher.

Das Modell zeigte nur selten vorsichtige Formulierungen.

GPT-5.4 mini: deutlich besser, aber nicht immer vorsichtig

Richtige Antworten: 34 von 50
Falsche Antworten: 16 von 50
Genauigkeit: 68%

Sicherheit der Antworten:
HI: 44 Antworten
LO: 5 Antworten
DK: 1 Antwort

Verbindung von Sicherheit und Richtigkeit:
Richtig + HI: 30
Falsch + HI: 14
Richtig + LO: 3
Falsch + LO: 2
Richtig + DK: 1



GPT-5.4 mini gab deutlich mehr richtige Antworten als Qwen und Deepseek.

Das Modell verwendete manchmal vorsichtige Formulierungen.

Trotzdem waren 14 falsche Antworten als HI formuliert.

GPT-5.4: die beste Leistung im Test

Richtige Antworten: 40 von 50
Falsche Antworten: 10 von 50
Genauigkeit: 80%

Sicherheit der Antworten:

HI: 41 Antworten
LO: 7 Antworten
DK: 2 Antworten

Verbindung von Sicherheit und Richtigkeit:

Richtig + HI: 36
Falsch + HI: 5
Richtig + LO: 2
Falsch + LO: 5
Richtig + DK: 2



GPT-5.4 hatte die höchste Genauigkeit.

Es machte auch die wenigsten falschen Antworten mit hoher Sicherheit.

GPT nutzte LO und DK häufiger als Qwen und Deepseek.

Dadurch zeigte GPT etwas öfter, dass eine Antwort unsicher oder nicht klar beantwortbar ist.

Fazit

Alle Modelle hatten Probleme, Unsicherheit zu zeigen.

Viele falsche Antworten klangen trotzdem sehr sicher.

Qwen und Deepseek waren besonders oft zu sicher.

GPT-5.4 mini und GPT-5.4 zeigten häufiger Vorsicht.

GPT-5.4 war im Test am besten, aber nicht fehlerfrei.

Modell	Richtig	Falsch	Genauigkeit	Falsch + HI
Qwen	25	25	50%	25
Deepseek	27	23	54%	20
GPT-5.4 mini	34	16	68%	14
GPT-5.4	40	10	80%	5